


Аналитические хранилища

Пространственная модель

ETL и ELT


Аналитические хранилища данных




Пространственная модель

Если реляционная модель акцентируется на целостности и эффективности ввода данных, то **размерная модель (Dimensional)** ориентирована в первую очередь на выполнение сложных запросов к БД.

В размерном моделировании для ХД принят стандарт модели, называемый **схемой звезда** (star schema), которая обеспечивает высокую скорость выполнения запроса посредством денормализации и разделения данных.




OLAP-куб



Осями многомерной системы координат служат основные атрибуты анализируемого бизнес-процесса.

Например, для продаж это могут быть товар, регион, тип покупателя. На пересечениях осей измерений (Dimensions) находятся данные, количественно характеризующие процесс — меры (Measures).

Kimball vs. Inmon



Отличия двух подходов:

1. Архитектура хранилища
 1. у Кимболла - пространственная организации
 2. у Инмона - нормализованная.
2. Физическая организации хранилища.
 1. у Инмона - это физически целостный реально существующий объект
 2. у Кимболла - скорее "виртуальный" объект. Коллекция витрин данных, которые могут быть пространственно разобщенными.

ETL – аббревиатура от Extract, Transform, Load



Какие задачи решает:

- Привести все данные к единой системе значений и детализации, попутно обеспечив их качество и надежность;
- Обеспечить аудиторский след при преобразовании (Transform) данных, чтобы после преобразования можно было понять, из каких именно исходных данных и сумм собралась каждая строка преобразованных данных.

Виды ошибок данных:

- Как случайные ошибки, возникшие на уровне ввода, переноса данных, или из-за багов;
- Как различия в справочниках и детализации данных между смежными ИТ- системами.

Как работает ETL система



Процесс загрузки данных

Задача этого этапа - затянуть в ETL данные произвольного качества для дальнейшей обработки. При проектировании процесса загрузки данных необходимо помнить о том что:

- Надо учитывать требования бизнеса по длительности всего процесса;
- Данные могут загружаться набегаящей волной;
- Данные могут перегружаться много раз;
- Данные всегда содержат ошибки;
- Надо учитывать возможность обогащения данных.

Процесс валидации


Данный процесс отвечает за выявление ошибок и пробелов в данных, переданных в ETL.

Главный вопрос – как вычислить возможные виды ошибок в данных, и по каким признакам их идентифицировать?

Типы данных	Внутри поля	По отношению к другим полям	Совместимость форматов при передачи между системами
Перечисление и текст	• Не из списка разрешенных значений • Отсутствие обязательных значений • Не соответствие формату (например, все договора должны нумероваться «ДГВ»)	• Не из списка разрешенных значений для связанного элемента • Отсутствие обязательных элементов для связанного элемента • Не соответствие формату для заданного элемента (например, для продукта «АИС» все договора должны нумероваться «АИСxxxxx»)	• Символы допустимые в одном формате, недопустимы в другом • Кодировка • Обратная совместимость • Новые значения (нет в мэппингах) • Устаревшие значения (не из списка разрешенных в целевой системе)
Числа и порядки	• Не число • Не в границах разрешенного интервала значений • Пропущено порядковое	• Не выполняется отношение • Присвоен неправильный порядковый номер • Разницы за счет разных правил округления значений	• Переполнение • Потеря точности и знаков • Несовместимость форматов при конвертации не в число
Даты и периоды		• День недели не соответствует дате • Сумма единиц времени не соответствует из-за разницы рабочие/не рабочие/праздничные/сокращенные дни	• Несовместимость форматов даты при передаче текстом • Ошибка точности отсчета и точности при передаче числом

Процесс мэппинга данных

Таблица замэпленных данных должна включать одновременно два набора полей – старых и новых аналитик, чтобы можно было сделать select по исходным аналитикам и посмотреть, какие целевые аналитики им присвоены, и наоборот:




Процесс агрегации данных

Этот процесс нужен из-за разности детализации данных в OLTP и OLAP системах.

OLTP система может содержать несколько сумм для одного и того же набора элементов справочников.



OLAP-системы — это, по сути, полностью денормализованная таблица фактов и окружающие ее таблицы справочников.



ETL vs ELT

В случае **ELT (Extract, Load, Transform)** данные сразу же загружаются после извлечения из исходных пулов данных.

- Промежуточная база данных отсутствует, что означает, что данные немедленно загружаются в единый централизованный репозиторий.
- Данные преобразуются в системе хранилища данных для использования с инструментами бизнес-аналитики и аналитики.



ВІ инструменты

Business Intelligence (BI) – это комплекс методов и компьютерных инструментов для сбора, хранения, обработки и визуализации данных, которые превращают транзакционную информацию в наглядные отчеты.

Главная цель ВІ – выделять ключевые метрики и тренды, помогать моделировать альтернативные сценарии и своевременно реагировать на изменения бизнеса.

ВІ-системы позволяют принимать:

- Оперативные решения
- Стратегические решения
- Объединять внутренние (финансовые, CRM) и внешние (рынок, конкуренты) данные



MOLAP (Multidimensional OLAP)


BI инструменты, которые перед построением отчетов собирают данные в особые структуры. Запросы к данным используют именно эти структуры.

Преимущества:

- Нет конкуренции с пользователями за ресурс СУБД
- Высокая скорость запросов

Недостатки:

- Только регламентное обновление данных
- Только заданные примитивы



ROLAP (Relational OLAP)


BI инструменты, которые отправляют запросы на получение данных напрямую в СУБД.

Преимущества:

- Построение real-time отчетов
- Реализация графиков любого уровня сложности

Недостатки:

- Конкуренция с пользователями
- При выполнении сложного запроса может нагружать СУБД



Классификация BI-инструментов

MOLAP подходит, если:

- Основные аналитические отчёты сформированы заранее и редко меняются
- Критична максимальная скорость отклика даже на сложные свёртки
- Объёмы (и число измерений) укладываются в возможность куба

Примеры систем:

- PowerBI

ROLAP подходит, если:

- Схема данных часто эволюционирует, добавляются новые поля или источники
- Нужно опираться на уже имеющийся DWH и минимизировать дублирование
- Допустима чуть более медленная, но гибкая аналитика

Примеры систем:

- SuperSet
- Grafana