


ETL-инструменты


Подходы к обработке данных

Batch Processing




- Большие порции данных
- Загрузка по регламенту, а следовательно и отставание в данных на принимающей стороне

Stream Processing



- Маленькие порции данных (часто в формате изменения)
- Загрузка приближенная к реальному времени



No Code & Low Code



- Используются визуальные инструменты и готовые модули
- Минимальное количество кода
- Для пользователей с минимальными навыками программирования

- Используются визуальные инструменты и готовые модули
- Нет возможности писать код
- Для пользователей без навыков программирования

Low Code приложения для автоматизации загрузки данных



NiFi для потоков обработки сообщений

Apache NiFi предоставляет возможность управления потоками данных из разнообразных источников в режиме реального времени с использованием графического интерфейса.


Интересные факты:

- NiFi базируется на технологии NiagaraFiles, ранее разрабатываемой агентством национальной безопасности США
- В ноябре 2014 года исходный код был открыт и передан Apache Software Foundation в рамках программы по передаче технологий NSA Technology Transfer Program.

Компоненты NiFi

NiFi состоит из трех основных компонентов:

- Flow Files – потоки файлов.
- Flow File Processor – своего рода «функции» с входами и выходами параметрами, которые выполняют широкий перечень типовых задач.
- Connections – задают направление движения FlowFiles между процессорами.



Flow Files – потоки файлов

Поточный файл является основным объектом обработки в Apache NiFi.

Он состоит из двух частей:

- Атрибуты, используемые процессорами NiFi для обработки данных, например:
 - UUID – идентификатор потокового файла
 - FileName – имя потокового файла
 - File Size – размер потокового файла
 - mime.type - MIME-тип потокового файла
- Контейнер с данными (payload), которые обрабатываются процессорами.

FlowFile

DETAILS

ATTRIBUTES

FlowFile Details	Content Claim
UUID 8ebb619b-d1dd-461e-8b34-f0a8de7a8ba9	Container default
Filename New Text Document.txt	Section 1
File Size 0 bytes	Identifier 1541399489168-1
Queue Position No value set	Offset 0
Queued Duration 00:00:29.433	Size 0 bytes
Lineage Duration 00:00:29.574	
Penalized No	

 DOWNLOAD

 VIEW


OK

Flow Files. Формат AVRO

AVRO - строчный формат хранения файлов, активно применяемый в экосистеме Apache Hadoop.

Широко используется в качестве платформы сериализации.

Avro сохраняет схему в независимом от реализации текстовом формате JSON, что облегчает ее чтение и интерпретацию.



Flow Files. Структура AVRO


Линейная структура данных формата Avro обеспечивает следующие преимущества:

- высокая скорость записи информации, что особенно важно в потоковых Big Data системах
- формат отлично подходит для ETL-хранилищ и витрин данных, где требуется чтение всех полей записи, а не избирательно по столбцам, как в колоночно-ориентированных форматах.

Sample AVRO schema in JSON format

```
{
  "type" : "record",
  "name" : "tweets",
  "fields" : [ {
    "name" : "username",
    "type" : "string",
  }, {
    "name" : "tweet",
    "type" : "string",
  }, {
    "name" : "timestamp",
    "type" : "long",
  } ],
  "doc:" : "schema for storing tweets"
}
```

Avro file structure




Flow File Processor – «функции»

Процессоры Apache NiFi являются основными блоками создания потока данных. Каждый процессор имеет разные функциональные возможности, что способствует созданию различных выходных потоковых файлов.

Отображаемые в GUI характеристики процессора:

- Processor Name – Пользовательское имя процессора
- Processor Type – Тип используемого процессора
- Active Tasks – Количество активных потоков
- Status Indicator – Статус процессора (включен/выключен)



Виды Flow File Processor-ов

Название	Примеры
Процессоры загрузки данных	GetFile, GetHTTP, GetFTP, GetKafka, ConsumeKafka
Процессоры маршрутизации и посредничества	RouteOnAttribute, RouteOnContent, ControlRate, RouteText
Процессоры доступа к базам данных	ExecuteSQL, PutSQL, PutDatabaseRecord, ListDatabaseTables
Процессоры извлечения атрибутов	UpdateAttribute, EvaluateJSONPath, ExtractText, AttributesToJSON
Процессоры системного взаимодействия	ExecuteScript, ExecuteProcess, ExecuteGroovyScript, ExecuteStreamCommand
Процессоры преобразования данных	ReplaceText, JoltTransformJSON
Отправка процессоров данных	PutEmail, PutKafka, PutSFTP, PutFile, PutFTP
Процессоры расщепления и агрегации	SplitText, SplitJson, SplitXml, MergeContent, SplitContent
HTTP-процессоры	InvokeHTTP, PostHTTP, ListenHTTP


Connections – направление движения FlowFiles


В потоке данных Apache NiFi потоковые файлы перемещаются от одного процессора к другому через соединение.

Каждый раз, когда создается соединение, разработчик выбирает одно или несколько отношений между этими процессорами.

Самые частые соединения:

- Success
- Failure





Пример NiFi-Flow

- Получили данные из БД с помощью запроса
- Разделили полученные записи на отдельные Flow-файлы
- Выделили из каждой записи атрибут
- Загрузили в Elasticsearch (распределённая система для полнотекстового поиска)

NiFi Registry

NiFi Registry - система версионирования NiFi Flow. Как гит, только для ETL.

NiFi Registry состоит из двух основных компонентов:

- Flow - поток данных NiFi на уровне группы процессов, который был помещен под контроль версий и сохранен в реестре.
- Bucket - контейнер, который хранит и организует потоки.



Шаблон взаимодействия с NiFi Registry

Типовые действия, которые можно выполнять в NiFi Registry:

- Создать пакет
- Добавить процесс под версионный контроль (работает только над группами)
- Закоммитить NiFi Flow
- Импортировать или экспортировать NiFi Flow

