

Методы оркестрации задач

Apache Airflow

Apache Airflow — это платформа управления обработкой данных с открытым исходным кодом (оркестратор).

Это open source проект, написанный на Python, был создан в 2014 году в компании Airbnb.

В 2016 году Airflow ушел в Apache Software Foundation, прошел через инкубатор и в начале 2019 года перешел в статус top-level проекта Apache.




Apache
Airflow

Основные сущности Apache Airflow

DAG (Directed Acyclic Graph) — это некоторое смысловое объединение ваших задач, которые вы хотите выполнить в строго определенной последовательности по определённому расписанию.

DAG состоит из операторов, которые являются единицей работы.



Операторы Apache Airflow


Оператор — это сущность, на основании которой создаются экземпляры заданий, где описывается, что будет происходить во время исполнения экземпляра задания.

Название оператора	Описание
BashOperator	Оператор для выполнения bash-команды
PythonOperator	Оператор для вызова Python-кода
PostgresOperator	Оператор для выполнения SQL-кода в СУБД PostgreSQL
MySqlOperator	Оператор для выполнения SQL-кода в СУБД MySql
SqlOperator	Оператор для выполнения SQL-кода
HTTPOperator	Оператор для работы с http-запросами
Sensor	Оператор ожидания события
EmailOperator	Оператор для отправки email'а
DummyOperator	"Пустой" оператор, используемый для группировки задач (Task)

Идемпотентность данных

Одна из ключевых концепций, лежащих в основе AirFlow — это хранение информации о каждом запуске DAG в соответствии с настроенным расписанием.


Запуск или перезапуск задачи с одинаковым набором данных для определенной даты в прошлом всегда приводит к одним и тем же результатам. Дополнительно появляется возможность запускать задачи одного DAG для разных временных меток одновременно.



Архитектура Apache Airflow

Apache Airflow
СОСТОИТ ИЗ:

- Web Server
- Metadata Database
- Планировщик (Scheduler)
- Executor
- Worker
- Директория с DAG-файлами



Примеры использования Apache Airflow

Где пригодится Airflow:

- Для проектирования, разработки и обслуживания систем обработки данных
- Для построения несложных витрин данных, отчётов или для подготовки данных для выгрузок, например, для машинного обучения
- Для автоматизации загрузки данных для тестирования приложения, настройки обмена информацией между базами данных или с внешними системами
- Для планирования и мониторинга процессов обработки данных